

Sarah-Maude Gagné
& Heidi Lavoie
Techniques de l'informatique
Groupe : 04318

Projet 2

Projet présenté à
M. Nicolas Payre
Département d'informatique
pour le cours
Exploration de nouvelles technologies

Cégep de Sherbrooke
20 octobre 2025

Table des matières

Description du site et des données choisies.....	3
Outil de webscraping utilisé	3
Méthode d'importation des données dans MongoDB Atlas	5
Schéma des documents dans votre collection	6
3 requêtes de sélection	7
Liens	8
Base MongoDB Atlas	8
Dépôt GitHub	8
Conclusion	8
Scrapy.....	8
MongoDB Atlas.....	8
Tableau indiquant la contribution de chaque coéquipier.....	9
Imprime écran	10

Description du site et des données choisies

Site choisi : Open library, catalogue en ligne de livres disponible à lire.

Données choisies : Les données choisies sont des livres de plusieurs catégorie.

URL cliquable : <https://openlibrary.org/>

Outil de webscraping utilisé

Outil choisi : Scrapy

URL cliquable : <https://www.scrapy.org/>

Fonctionnement de l'outil :

1. Création d'un projet Scrapy
2. Exécution d'un « *Scrapy spider* » (pour récupérer les données du site)
3. Exporter les données récupérées (format JSON, CSV ou XML)
4. Utiliser « *Scrapy Shell* » (pour tester et débbugger la logique *Scraping*)

Scrapy est un *framework* Python *open-source* qui extrait des données de sites web en envoyant des requêtes HTTP, en téléchargeant le contenu des pages, en le parsant avec des sélecteurs CSS ou XPath pour en extraire les informations (utilisant les « *Spiders* »), puis en structurant et en stockant ces données via des pipelines. Son fonctionnement est dirigé par un moteur qui coordonne les araignées (« *Spiders* ») et l'ordonnanceur pour gérer le flux de requêtes et de réponses, offrant ainsi un moyen efficace et extensible de réaliser du web *scraping* pour des projets de toute envergure.

Source : <https://datascientest.com/scrapy-web-scraping-tout-savoir>

Étapes :

Installation de Scrapy :

1. pip install scrapy

Dans VSCode :

2. python -m scrapy startproject hl_nouvelles_technos
3. cd hl_nouvelles_technos
4. python -m scrapy genspider hl_projet2 quotes.toscrape.com

Dans Users/lavoi /hl_nouvelles_technos/hl_nouvelles_technos/spiders/hl_projet2.py :

5. Modifier le code de la classe HlProjet2Spider
6. python -m scrapy crawl hl_projet2 -O livres.json

Modifier fichier settings.py :

7. Plusieurs modifications à faire, beaucoup de recherche

Modifier le fichier hl_projet2.py :

8. Plusieurs modifications à faire, beaucoup de recherche

Installation d'un traducteur pour prendre les données en français :

9. `pip install deep-translator`

Ajouter dans le fichier `hl_projet2.py` pour la traduction :

10. Quelques modifications à faire (imprime écran 1)

Dans VSCode :

11. `python -m scrapy crawl hl_projet2 -o livres.json`

Test avant de récupérer toutes les données :

12. Scrape une dizaine de données (`python -m scrapy crawl hl_projet2 -o livres.json`)
13. Essayer d'importer le fichier dans MongoDB Atlas pour s'assurer que le format est bien
14. Quelques modifications pour faciliter l'import dans MondoBD Atlas

Final :

15. Scrape 2500 données (attendre longtemps)
16. Fichier json -> csv

Méthode d'importation des données dans MongoDB Atlas

Les données obtenues à partir du Scraping ont été importé directement dans MongoDB Compass via l'option « Add data », puis importé dans un collection nommée « Livres » du projet « projet2 ».

Schéma des documents dans votre collection

Chaque document dans la collection « Livres » contient les champs suivants :

_id : ObjectId (identifiant généré automatiquement par MongoDB)

id_livre : nombre entier

titre : chaîne de caractères

auteur : chaîne de caractères

categorie : chaîne de caractères

sous_categorie : tableau de chaînes

nombre_editions : nombre entier

note_popularite : nombre (float)

image_url : chaîne (URL de l'image de la couverture du livre)

3 requêtes de sélection

1.	Requête : <code>db.projet2.find({ auteur: "Stephen King" })</code> Explication : La requête sort tous les livres dont l'auteur est Stephen King.
2.	Requête : <code>db.projet2.find({ sous_categorie: "succube" })</code> Explication : La requête sort tous les livres ayant comme sous-catégorie « Roman classique ».
3.	Requête : <code>db.projet2.find().sort({ note_popularite: -1 })</code> Explication : La requête trie les livres du plus populaire au moins populaire.

Liens

Base MongoDB Atlas

Une invitation a été envoyé à l'adresse courriel indiqué dans l'énoncé du projet.

<https://cloud.mongodb.com/v2/68e3cdbdd5d52669661afa9a#/metrics/replicaSet/68ec63e96644d00b04753e17/explorer/projet2/Livres/find>

Dépôt GitHub

https://github.com/twinkletoe103/projet2_nouvelles_technos
https://github.com/twinkletoe103/projet2_nouvelles_technos.git

Conclusion

Impression des technologies utilisées :

Scrapy

Scrapy a quand même été facile à utiliser, surtout parce qu'il y a beaucoup de documentation. Il y a quand même eu quelques défis, au début nous avons choisi le site Best Buy, mais Best Buy bloque ce genre d'outil, donc j'ai essayé de contourner les protections avec Playwright, mais même après plus d'une heure, je n'étais pas en mesure de ramasser aucune donnée (à cause des protections et du fait que les informations sont chargées avec du JavaScript et non du HTML). J'ai donc décidé de changer de site, pour en utiliser un moins protégé et qui utilisait moins de JS. Je suis tombé sur le site Open library, et j'ai décidé de l'utiliser. Avec ce site qui ne bloque pas les outils comme Scrapy et qui utilise peu de JavaScript, c'était vraiment plus facile d'explorer l'outil et d'apprendre à l'utiliser. Ensuite, même si je donnais l'URL du site en français, les données recueillies étaient en anglais, mais Scrapy permet d'utiliser la traduction Google, donc j'ai adapté mon *spider* et après quelques essais, les données étaient en français. Donc pour le projet, j'ai eu quelques problèmes, mais avec un site plus accessible, Scrapy est facile à utiliser et beaucoup de choses sont possibles avec l'outil.

MongoDB Atlas

MongoDB Atlas est très facile d'utilisation, j'ai été agréablement surprise. Je n'avais presque aucune configuration à faire et la base de données s'est créée. Il est aussi très facile d'importer et exporter des données, bien que pour ce faire, on doit télécharger l'application MongoDB Compass. Il est tout de même possible avec le site web en faisant un copier-coller, mais j'ai quand même décidé d'aller de l'avant avec Compass, qui est plus simple. Malheureusement, seulement une base de données gratuite est possible par compte, ce qui est désagréable quand on a plusieurs projets. En plus, Compass ne peut pas être utilisé au cégep, donc j'ai fait cette partie du projet chez moi. J'ai l'impression que MongoDB Atlas est très bon pour de petits projets, mais pour des plus gros projets, je crois qu'un autre hébergement serait plus adapté.

Tableau indiquant la contribution de chaque coéquipier

	Tâches réalisées	% participation
Heidi Lavoie	Création du rapport Extraction de 2500 éléments et test Exporter les données dans un fichier JSON	40%
Sarah-Maude Gagné	Convertir le fichier JSON en CSV Importer le fichier CSV dans une collection Production de 3 requêtes de sélection (find) Schéma des documents dans la collection	40%
Ensemble	Recherche du site Recherche de l'outil de webscraping Rédaction du rapport	20%

Imprime écran

```
# traduction avec cache et gestion d'erreur
def translate_text(self, texte):
    if not texte:
        return ""
    texte = texte.strip()
    if texte in self.cache_traductions:
        return self.cache_traductions[texte]
    try:
        traduction = self.translator.translate(texte)
        self.cache_traductions[texte] = traduction
        return traduction
    except Exception as e:
        # retour du texte original si problème
        self.logger.warning(f"Erreur de traduction pour '{texte}': {e}")
        return texte

# traduction des données texte
titre = self.translate_text(titre)
auteur = self.translate_text(auteur)
categorie = self.translate_text(categorie.replace("_", " ").title())
sous_categorie = [self.translate_text(s) for s in sous_categorie] # traduction de tout le tableau
```

Imprime écran 1